

Data Engineering for AI: From Raw Data to a Trustworthy Dataset

(Data Engineering pour l'IA : de la donnée brute à un dataset de confiance)

Hands-on: the step that fails in silence (le maillon qui échoue en silence)

Babacar Ndao · co-fondateur et CLO, Afriklang

Jeudi 27 août · 13h30 à 15h30 · Salle F1



The Pipeline, End to End

(Le pipeline, de bout en bout)



Un seul jeu de données traverse les deux heures : le manifeste d'un corpus vocal, 200 lignes, français et éwé.

`raw_manifest.csv` → `clean_manifest.csv` → `annotated_manifest.csv` → dataset final

**Laquelle de ces étapes,
si elle échoue, ne se voit pas ?**

Three Kinds of Failure

(Trois façons d'échouer)

Un défaut de collecte se voit.

Locuteurs, accents, registres manquants : la distribution le montre.

Un défaut de nettoyage se voit et se corrige.

On relance le script sur les données brutes.

Un défaut d'annotation ne se voit nulle part.

Une fois les labels traités comme vérité de référence, tout ce qu'on mesure contre eux hérite de leurs erreurs. Le F1 sera excellent, et faux.

Toutes ces étapes comptent. Une seule échoue en silence.

The Manifest

(Le manifeste : un tableau qui décrit des enregistrements)

id	identifiant de l'enregistrement
audio_path	chemin du fichier
duration_s	durée en secondes
sample_rate	fréquence d'échantillonnage
channels	nombre de canaux
language	fr ou ee
transcription	le texte prononcé
speaker_id	identifiant du locuteur
region	zone géographique
recorded_at	date d'enregistrement
source	provenance de la collecte

Les séquences 2 et 3 contrôlent les colonnes techniques.

La séquence 4 annote le sentiment sur la colonne transcription.

Même fichier du début à la fin.

Why We Never Open the Audio

(Pourquoi on ne touche pas aux fichiers audio)

Dans un pipeline réel, les contrôles automatiques tournent d'abord sur le manifeste pour signaler les enregistrements suspects, et seuls les cas signalés partent en écoute humaine.

Écouter dix mille fichiers n'est pas une option. Filtrer dix mille lignes puis écouter les deux cents suspectes en est une.

L'écoute humaine ne disparaît pas : elle devient ciblée. C'est le contrôle automatique qui décide où elle se pose.

10 000

lignes filtrées par le script

200

écoutées par un humain

Three Sounds, Then a Table

(Data Inspection : trois écoutes, puis un tableau)

- 1 Un enregistrement propre, conforme.
- 2 Un enregistrement tronqué : moins d'une seconde.
- 3 Une transcription qui ne correspond pas à ce qu'on entend.

Vous venez d'entendre trois problèmes. Vous allez devoir les trouver dans un tableau de deux cents lignes, sans jamais écouter.

CONSIGNE

Trouvez tout ce qui ne va pas avec ce manifeste.

8

minutes

En binômes · notebook, section 2

Notez chaque famille de problème, avec un exemple

Eleven Planted Defects

(Les onze défauts, quantités exactes)

Défaut	Manifestation
Doublons exacts	12 lignes strictement identiques
Doublons approximatifs	8 lignes : un espace ou une majuscule d'écart
Durées aberrantes	0,2 s et 47 s
Fréquence incohérente	8000 Hz au lieu de 16000
Canaux incohérents	stéréo là où le mono est attendu
Langue mal renseignée	6 lignes marquées ee, transcription en français
Transcription vide	9 lignes
Débit impossible	40 mots annoncés sur 0,6 s
Encodage cassé	mojibake sur 5 lignes
Identifiant locuteur manquant	15 lignes
Date impossible	recorded_at dans le futur

Quality Gates

(Écrire les règles de qualité)

```
# Fournies (scaffolding)
def check_duration(row, min_s=0.5, max_s=20.0): ...
def check_sample_rate(row, expected=16000): ...
def check_transcription_present(row): ...

# À remplir, un test fourni pour chacune
def check_channels(row, expected=1):           # TODO
def check_words_per_second(row, max_wps=6.0):  # TODO
def check_language_consistency(row):           # TODO
def check_metadata_complete(row):              # TODO

def quality_gate(row): # agrège et motive : (accepted, reasons)
```

CONSIGNE

Remplissez les quatre fonctions.

12

minutes

Notebook, section 3 · les tests vous disent où vous en êtes

Bloqué ? L'indication de déblocage est dans la cellule

**Un seuil est une décision,
pas une vérité.**

Signaler n'est pas prouver

4

Measuring Label Reliability

(Mesurer la fiabilité des labels)

45 minutes.

Three Labels, One Page of Rules

(La tâche et le guide v1)

positif satisfaction, approbation, plaisir

negatif mécontentement, critique, déception

neutre pas d'émotion claire

Le guide v1 tient sur une page. On le lit à voix haute, puis chacun annote avec lui, et lui seul.

Aucune question sur les cas particuliers : cela fait partie de l'exercice.

CONSIGNE

**Annotez seul. Ne consultez
pas votre binôme.**

13

minutes

40 phrases · guide v1 · groupe FR ou ÉWÉ

Saisie dans votre onglet : `annoteur_A`, `annoteur_B`

80%

d'accord brut peut valoir un Kappa proche de zéro.

Deux annotateurs qui répondent « neutre » partout sont d'accord. Ils n'ont rien jugé.

Six Holes in Guide v1

(Les six trous du guide, découverts par vos désaccords)

Sentiment mixte

« Le service était lent mais le plat excellent. »

Neutre fourre-tout

« pas d'émotion claire » : le refuge des hésitations

Objet du sentiment

« Il a dit qu'il était très satisfait. »

Ironie

« Bravo, encore une coupure de courant. »

Mauvaise nouvelle factuelle

« Le prix du riz a augmenté de 15 %. »

Questions et impératifs

« Pouvez-vous confirmer la date ? »

Chaque trou devient une règle explicite au tableau : c'est votre guide v2.

CONSIGNE

**20 nouvelles phrases, avec
le guide v2.**

6

minutes

Mêmes binômes, même silence · saisie colonnes round 2

Puis recalcul du Kappa : v1 contre v2, dans votre groupe

Your Kappa, Before and After

(v1 contre v2, à l'intérieur de chaque groupe)

Kappa · guide v1

round 1, 40 phrases

à remplir en séance

Kappa · guide v2

round 2, 20 phrases

à remplir en séance

The Model Helps. The Human Decides.

(Pré-annotation IA et validation humaine)



« Sur une tâche d'analyse de sentiment en wolof, avec un protocole documenté, nos annotateurs natifs atteignent 90 % de F1 macro là où le meilleur modèle testé en zéro-shot plafonne à 45 %. Cette mesure porte sur cette tâche et ce corpus. Elle ne dit pas qu'un modèle est incapable de traiter le wolof. »

Benchmark Afriklang · tâche et protocole documentés

A Name That Carries Its Meaning

(Assembler, nommer, documenter)

```
taiss2026_sentiment_ee-fr_v1.0/  
├─ data/  
│   ├── raw_manifest.csv  
│   ├── clean_manifest.csv  
│   └─ annotated_manifest.csv  
├─ splits/  train · validation · test  
├─ scripts/  
├─ annotation_guide_v2.md  
├─ quality_report.md  
└─ dataset_card.md
```

taiss2026 · sentiment · ee-fr · v1.0

origine · tâche · langues · version. Un dossier nommé data2 est irretrouvable dans six mois.

Aucun locuteur dans deux splits.

Sinon le modèle reconnaît la voix au lieu d'apprendre la tâche : le score de test devient un mensonge optimiste. Le manifeste porte speaker_id, la règle tient en trois lignes.

La carte porte le Kappa.

C'est ce qui rend le dataset auditable par quelqu'un d'autre dans six mois.

At Scale

(Ce même principe, sur 24 langues)

24 langues · plus de 200 contributeurs natifs

À l'échelle, le consensus de binôme devient un arbitrage :
trois annotateurs, un arbitre.

Le guide d'annotation devient un document vivant, versionné comme du code.

Les plus rigoureux d'aujourd'hui peuvent rejoindre le réseau de contributeurs rémunérés : la feuille de contacts circule.

